

Pertemuan 2

Pengantar Statistik Data Science

“A data scientist is someone who knows more statistics than a computer scientist and more computer science than a statistician” – Joel Gruss

Peran Statistik dalam Data Science

Statistik tidak hanya menyediakan alat, metode, dan prinsip yang penting bagi seorang data scientist untuk menggali, menganalisis, dan mengungkap insight berharga dari data, tetapi juga membantu mereka untuk memiliki pemahaman yang lebih mendalam terhadap data tersebut, terdapat beberapa peran statistika dalam data science :

Konsep Statistik Data Science

1. **Statistika Deskriptif**
2. **Statistika Inferensial**
3. Analisa Regressi
4. Data Sampling
5. Reduksi Dimensi
6. Seleksi Fitur
7. Pengujian Hipotesis
8. Uji Statistik

Statistika Deskriptif

Statistik deskriptif merupakan cabang statistik yang berkaitan dengan pengumpulan dan penyajian suatu data

Komponen dalam Statistika Deskriptif

1. Rata-rata: Mengukur nilai rata-rata dalam distribusi data numerik
2. Median: Merupakan nilai tengah dari data
3. Variansi: Mengukur sebaran data
4. Standar Deviasi: Akar kuadrat dari variansi, memberikan ukuran yang lebih mudah diinterpretasikan tentang variasi data
5. Persentil: Menunjukkan persentase titik data yang sama atau kurang dari nilai tertentu dalam kumpulan data
6. IQR (Rentang Interkuartil): Mengukur jarak antara kuartil pertama dan kuartil ketiga yang membantu mengidentifikasi nilai tengah dari 50% data
7. Skewness: Menggambarkan ketidaksimetrisan dalam distribusi data
8. Kurtosis: Mengukur keberadaan ekor dalam distribusi data
9. PDF (Fungsi Kerapatan Probabilitas): Menggambarkan kemungkinan bahwa variabel acak kontinu akan mengambil nilai tertentu dalam rentang tertentu.
10. CDF (Fungsi Kerapatan Kumulatif): Menyatakan probabilitas kumulatif bahwa variabel acak kurang dari atau sama dengan nilai tertentu

Contoh Penerapan Statistika Deskriptif Dalam Data Science

Data set

Produc_id	Kategori	Harga	Unit_terjual	Revenue
A001	Elektronik	200	10	2000
A002	Pakaian	50	10	500
A003	Makanan	25	2	50

Rangkuman data

Mean (rata-rata)

Misalnya, menghitung rata-rata harga produk di seluruh kategori.

Contoh: Rata-rata harga produk adalah 25.

Median:

Mencari nilai tengah dari harga produk untuk mengetahui harga median.

Contoh: Median harga produk adalah 20.

Modus:

Menentukan harga yang paling sering muncul dalam dataset.

Contoh: Modus harga produk adalah 15.

Contoh Penerapan Statistika Deskriptif Dalam Data Science

Analisis Dispersi

Range:

Menghitung selisih antara harga produk tertinggi dan terendah.

Contoh: Rentang harga adalah 90 (dari 10 hingga 100).

Variance (Variansi):

Mengukur seberapa jauh harga produk tersebar dari rata-rata.

Contoh: Variansi harga produk adalah 200.

Standard Deviation (Standar Deviasi):

Mengukur deviasi standar untuk memahami seberapa tersebar harga produk dari rata-rata.

Contoh: Standar deviasi harga produk adalah 14

Contoh Penerapan Statistika Deskriptif Dalam Data Science

Analisis Distribusi

Histogram:

Membuat histogram dari harga produk untuk melihat distribusi harga.

Contoh: Histogram menunjukkan bahwa sebagian besar produk berada di kisaran harga 10 hingga 30.

Boxplot:

Membuat boxplot untuk mengidentifikasi outlier dalam harga produk.

Contoh: Boxplot menunjukkan adanya beberapa produk yang memiliki harga jauh lebih tinggi dari harga rata-rata (outlier).

Contoh Penerapan Statistika Deskriptif Dalam Data Science

Analisis Per Kategori

Mean Units Sold per Category:

Menghitung rata-rata unit yang terjual untuk setiap kategori.

Contoh: Rata-rata unit terjual untuk kategori Elektronik adalah 50 unit, sedangkan untuk Pakaian adalah 30 unit.

Total Revenue per Category:

Menghitung total pendapatan yang dihasilkan oleh setiap kategori.

Contoh: Total pendapatan dari kategori Elektronik adalah 15,000, sementara dari kategori Pakaian adalah 8,000.

Contoh Penerapan Statistika Deskriptif Dalam Data Science

Korelasi Antar variable

Correlation Coefficient: Menghitung korelasi antara harga produk dan unit terjual untuk melihat hubungan antara keduanya.

Contoh: Korelasi antara harga dan unit terjual adalah -0.4, yang menunjukkan korelasi negatif sedang (harga lebih tinggi cenderung berhubungan dengan penurunan unit terjual).

Contoh Penerapan Statistika Deskriptif Dalam Data Science

Interpretasi Hasil

Dari analisis ini, kita bisa melihat bahwa produk dengan harga lebih rendah cenderung terjual lebih banyak (korelasi negatif). Selain itu, kategori Elektronik memiliki penjualan tertinggi, yang mungkin menunjukkan bahwa produk-produk dalam kategori ini sangat populer atau memiliki nilai lebih tinggi bagi konsumen.

Adanya outlier dalam data harga produk menunjukkan bahwa ada beberapa produk yang harganya jauh lebih tinggi dari rata-rata, yang mungkin perlu ditinjau lebih lanjut (misalnya, apakah produk tersebut eksklusif atau premium).

Statistika Inferensial

Statistik inferensial adalah cabang statistik yang melibatkan penggunaan data untuk membuat inferensi, prediksi, atau generalisasi tentang populasi berdasarkan data sampel. Statistik inferensial dapat membantu Anda untuk menyimpulkan atau membuat pernyataan tentang kelompok yang lebih besar (populasi) dengan menganalisis sub kelompok yang lebih kecil (sampel) yang merupakan representatif dari kelompok besar tersebut.

Komponen dalam Statistika Inferensial

1. **Pengujian Hipotesis:** Merumuskan hipotesis tentang parameter populasi (misalnya, rata-rata populasi) dan menggunakan data sampel untuk menguji apakah hipotesis ini didukung atau ditolak
2. **Estimasi:** Mengestimasi parameter populasi berdasarkan data sampel
3. **Interval Kepercayaan:** Menyediakan rentang nilai dimana kemungkinan di dalamnya terdapat parameter populasi
4. **Uji Statistik:** Beberapa contoh uji statistik yang sering digunakan adalah uji t, uji chi-kuadrat, ANOVA, dan analisis regresi untuk membandingkan kelompok, menilai hubungan dan membuat prediksi

Contoh Penerapan Statistika Inferensial Dalam Data Science

Dataset Contoh

Branch: Cabang toko (Cabang A atau Cabang B).

Revenue: Pendapatan yang dihasilkan oleh masing-masing cabang.

Tujuan Analisis

Mengetahui apakah terdapat perbedaan signifikan dalam rata-rata pendapatan antara Cabang A dan Cabang B.

Contoh Penerapan Statistika Inferensial Dalam Data Science

Langkah-Langkah Analisis Inferensi

1. Menyusun Hipotesis

• **Hipotesis Nol (H_0):** Tidak ada perbedaan dalam rata-rata pendapatan antara Cabang A dan Cabang B.

$$H_0: \mu_A = \mu_B$$

• **Hipotesis Alternatif (H_1):** Ada perbedaan dalam rata-rata pendapatan antara Cabang A dan Cabang B.

$$H_1: \mu_A \neq \mu_B$$

2. Menentukan Tingkat Signifikansi

• Pilih tingkat signifikansi (α), misalnya 0.05 (5%).

Contoh Penerapan Statistika Inferensial Dalam Data Science

Uji Hipotesis

Uji Statistik: Gunakan *t-test* untuk dua sampel independen karena kita membandingkan rata-rata dari dua kelompok yang berbeda (Cabang A dan Cabang B).

Asumsi: Diasumsikan bahwa data mengikuti distribusi normal dan kedua kelompok memiliki variansi yang sama.

Misal data pendapatan untuk masing-masing cabang

revenue_A = [500, 520, 510, 530, 515, 500, 505]

revenue_B = [490, 480, 495, 485, 475, 490, 500]

Melakukan independent t-test t_stat , p_value = stats.ttest_ind(revenue_A, revenue_B)

Nilai p (p-value): Nilai p dihitung untuk menentukan apakah hasil uji statistik signifikan.

Keputusan: Bandingkan nilai p dengan tingkat signifikansi (α). Jika $p < \alpha$, maka tolak H_0 .

Contoh Penerapan Statistika Inferensial Dalam Data Science

Interpretasi Hasil

Misalkan hasil *t-test* memberikan $p\text{-value} = 0.03$.

Karena $p\text{-value} (0.03) < \alpha (0.05)$, kita menolak hipotesis nol.

Kesimpulan: Ada bukti statistik yang cukup untuk mengatakan bahwa terdapat perbedaan signifikan dalam rata-rata pendapatan antara Cabang A dan Cabang B.

Confidence Interval (Opsional)

Kita juga bisa menghitung interval kepercayaan (Confidence Interval) untuk rata-rata perbedaan pendapatan antara dua cabang tersebut.

Contoh: Interval kepercayaan 95% menunjukkan bahwa kita 95% yakin bahwa rata-rata perbedaan pendapatan antara kedua cabang terletak dalam kisaran tertentu.

Perbedaan Utama Antara Statistik Deskriptif dan Statistik Inferensial

ASPEK	STATISTIKA DESKRIPTIF	STATISTIKA INFERENSIAL
Maksud	Meringkas dan menjelaskan fitur kumpulan data	Membuat kesimpulan, prediksi, atau generalisasi tentang suatu populasi berdasarkan data sampel
Cakupan	Berfokus pada data sampel tertentu	Memperluas temuan ke populasi yang lebih besar
Tujuan	Menjelaskan karakteristik data tanpa menggeneralisasi	Menggeneralisasi temuan dari sampel ke populasi
Contoh	Ukuran tendensi sentral, dispersi, distribusi frekuensi, representasi grafis	Pengujian hipotesis, analisis regresi, interval kepercayaan
Analisis Data	Memberikan ringkasan dan visualisasi data	Menarik kesimpulan, menguji hipotesis, dan membuat prediksi
Representasi Populasi	Mewakili fitur dalam sampel saja	Mewakili ciri-ciri populasi yang lebih besar
Teknik Statistik	Mean, median, mode, range, variance, standard deviation, histograms, box plots, etc.	Hypothesis testing, regression analysis, confidence intervals
Sasaran	Untuk memberikan wawasan tentang karakteristik kumpulan data	Untuk membuat prediksi atau menarik kesimpulan tentang suatu populasi

Pemusatan dan Penyebaran Data

Rumus yang digunakan untuk mengukur pemusatan data selalu dibedakan untuk data yang tidak dikelompokkan dan data yang dikelompokkan.

Rerata (Mean)

Rerata merupakan konsep secara awam mengenai rata-rata.

Persamaan untuk data Tunggal (tidak dikelompokkan)

Dimana :

$$\bar{x} = \frac{\sum x}{n}$$

$\bar{x}$ = rerata

Σ = huruf besar Yunani sigma, yang berarti jumlahkan

x = nilai suatu hasil pengamatan atau observasi

$$\mu = \frac{\sum x}{N}$$

Σx = jumlahkan semua observasi

n = jumlah semua observasi

Persamaan untuk data yang dikelompokkan

Dimana :

$$\bar{x} = \frac{\sum f \cdot x_i}{\sum f}$$

$\bar{x}$ = titik tengah (mid point) kelas interval ke i

x_i = titik tengah interval kelas

f = frekwensi observasi pada kelas interval ke i
 $\sum f$ = jumlahkan frekwensi tiap kelas interval

Median

Median merupakan nilai tengah dari sekelompok data yang nilai tiap observasi telah disusun dari yang terkecil ke terbesar. Median digunakan untuk mengukur pemusatan kalau distribusi mencong (skewed) secara jelas

Median Untuk Data Tidak dikelompokkan

Untuk data tidak dikelompokkan

1) Bila jumlah observasi ($=n$) ganjil, maka median adalah nilai observasi ke: $\frac{n+1}{2}$ dari urutan nilai observasi kecil ke besar.

Contoh : 5, 4, 5, 6, 7, 1, 5, 3, 4, 6, 9. Tentukan median

Urutkan data : 1, 3, 4, 4, 5, 5, 5, 6, 6, 7, 9

$$\text{Median } (M_e) = \frac{n+1}{2} = \frac{11+1}{2} = 6$$

Bila banyaknya observasi ($=n$) genap, maka median adalah nilai di antara observasi ke: $\frac{n}{2}$ dan $\frac{n}{2}+1$, diambil rata-rata.

Contoh : 1, 3, 4, 4, 5, 5, 5, 6, 6, 7

$$n = 10 \rightarrow \frac{n}{2} = 5 \text{ dan } 5+1 = 6$$

$$M_e = \frac{5+6}{2} = 5,5$$

Median Untuk data dikelompokkan

Untuk data dikelompokkan

$$\text{Median } (M_e) = Lm + \frac{w \left(\frac{n}{2} - cf \right)}{fm}$$

Dimana :

M_e = Median

Lm = Batas bawah dari kelas interval
dimana median berada (kelas median)

n = banyaknya observasi

Cf = frekuensi kumulatif dari kelas interval
sebelum kelas median

W = lebar kelas interval dimana median
berada

Modus

Modus merupakan nilai yang paling sering muncul (frekuensi terbesar) dari seperangkat data atau observasi. Mencerminkan yang paling tipikal atau kasus yang paling umum. Kalau kita ingin segera mengetahui nilai pemusatan, maka kita menghitung modus. Seperangkat data dapat saja tidak memiliki modus, tetapi sebaliknya dapat pula memiliki beberapa modus. Kalau satu modus saja disebut unimodal, dua modus disebut bimodal dan kalau tanpa modus disebut nonmodal.

Modus Untuk Data Tidak dikelompokkan

Untuk data tidak dikelompokkan

Modus (*crude mode*) = nilai yang paling sering muncul

Contoh : 1, 3, 4, 4, 5, 5, 5, 6, 6, 7

$M_0 = 5$

Modus Untuk data dikelompokkan

Modus = titik Tengah dari kelas interval yang memiliki frekuensi terbesar

$$\text{Median } (M_o) = Bb + w \left(\frac{d_1}{d_1 + d_2} \right)$$

Interval kelas	f_i
164,5 – 167,5	6
168,5 – 171,5	7
172,5 – 175,5	8
176,5 – 179,5	11
180,5 – 183,5	7
184,5 – 187,5	6
188,5 – 191,5	5
Jumlah	50

$$\begin{aligned}
 M_o &= 176 + 7 \frac{11 - 8}{(11 - 8) + (11 - 7)} \\
 &= 176 + 7 \left(\frac{3}{7} \right) \\
 &= 176 + 3 \\
 &= 179
 \end{aligned}$$

Contoh Kasus

Hitung : rerata, median, modul lama perawatan dari data pasien berikut!

Pasien ke	Lama perawatan (hari)	Pasien Ke	Lama Perawatan (hari)
1	29	6	14
2	14	7	28
3	11	8	14
4	24	9	18
5	14	10	22

Mean:

$$\bar{x} = \frac{\sum x}{n} = \frac{11+14+14+14+14+18+22+24+28+29}{10}$$

$$\bar{x} = \frac{188}{10} = 18,8 \text{ hari}$$

Median

Urutan nilai observasi adalah sebagai berikut :

11; 14; 14; 14; 14; 18; 22; 24; 28; 29

Karena banyaknya observasi genap, maka median merupakan rata-rata nilai dari observasi

$$\text{ke } \frac{n+1}{2} = \frac{10}{2} = 5 \text{ dan } \frac{n}{2} + 1 = 6$$

$$\text{Median} = \frac{14+18}{2} = 16 \text{ hari}$$

Mean:

Oleh karena 14 yang paling banyak muncul maka Modusnya adalah 14 hari