

Pertemuan 9

Exploratory data Analysis (EDA)

Konsep EDA (Exploratory Data Analysis)

Exploratory Data Analysis adalah suatu metode eksplorasi terhadap suatu data. **Exploratory Data Analysis** dapat menggunakan teknik aritmatika ataupun teknik visual grafik. Dari teknis tersebut dapat membuat hasil rangkuman atau pengolahan dari data mentah yang ada. Exploratory Data Analysis ini dapat digunakan untuk mencari suatu pola atau tren yang ada dari hasil visualisasi data

Pentingnya EDA (Exploratory Data Analysis)

- Memahami data secara mendalam
- Identifikasi dan penanganan Outliers
- Mengungkap hubungan tersembunyi antar variable
- Mengurangi risiko kesalahan analisis
- Membantu memilih model yang tepat
- Mengambil keputusan berdasarkan data
- Visualisasi data untuk efektivitas dalam komunikasi

Teknik Exploratory Data Analysis

3 Teknik Utama Dalam Exploratory Data Analysis

1. Statistik deskriptif
2. Analysis Univariate
3. Analisis Bivariate

Analysis Univariate

Menganalisis kolom secara terpisah dan melihat distribusi datanya. Univariate analysis secara umum terbagi dua, yaitu numerik dan kategorik. Analisis ini digunakan juga dengan tujuan untuk mengambil kesimpulan dengan menggunakan beberapa analisis inferensial yang mungkin digunakan.

Analysis Multivariate

Menggabungkan beberapa kolom dengan tujuan menemukan hubungan antara satu kolom dengan kolom lainnya. Analisis multivariat ini melibatkan variabel dalam jumlah lebih atau sama dengan tiga variabel

Contoh EDA Dengan Statistik Deskriptif

Pada bahasa python, kita dapat menggunakan statistik deskriptif untuk melihat ringkasan dari data secara keseluruhan, salah satunya adalah dari data frame dengan menggunakan fungsi `describe()`, yaitu sebagai berikut

```
print(df.describe())
```

	usia	pendapatan	pengeluaran
count	100.000000	100.000000	100.000000
mean	44.070000	50584.244853	29389.428888
std	14.447575	15273.856641	10110.549898
min	20.000000	20901.331721	6819.317518
25%	33.000000	38368.134977	22668.439365
50%	43.000000	49051.087929	28785.440713
75%	58.000000	61242.649463	35982.650796
max	69.000000	94154.951247	60610.952144

fungsi ini dapat memberikan informasi mengenai nilai rata-rata, standar deviasi dan interquartile range


Identifikasi Pola dan Anomali

Anomali merupakan sesuatu yang tidak normal alias tidak seperti umumnya dapat dikatakan peristiwa mencurigakan yang menonjol dari pola dasar. Dalam konteks analisis data, setiap titik data yang memiliki nilai sangat berbeda dibandingkan kebanyakan suatu kumpulan nilai maka disebut anomali atau dikenal juga outlier. Titik data outlier berarti memiliki perbedaan nilai yang signifikan dengan nilai-nilai lainnya.

Jenis-jenis Anomali

1. Anomaly titik

Anomali titik didefinisikan sebagai titik data tunggal yang tidak biasa dibandingkan dengan data lainnya. Misalnya anomali ini digunakan pada kasus mendeteksi penipuan MasterCard berdasarkan jumlah yang dibelanjakan.




<https://blog.algorit.ma/cara-deteksi-anomali/>

Jenis-jenis Anomali

2. Anomaly Kontekstual



Disebut juga outlier bersyarat, anomali kontekstual berisi titik data yang menyimpang secara signifikan dari titik data lain yang didasarkan pada konteks spesifik tertentu. Anomali semacam ini dapat kita temukan dalam data berbasis time-series. Misalnya jumlah yang dihabiskan untuk bensin setiap hari selama hari kerja adalah normal tetapi akan terlihat ganjil saat dihabiskan untuk liburan.



Jenis-jenis Anomali

3. Anomaly Kolektif

Anomali kolektif adalah kumpulan titik data serupa yang dapat dianggap tidak normal jika dibandingkan dengan data lainnya. Misalnya, periode suhu panas selama 10 hari berturut-turut dapat dianggap sebagai anomali kolektif. Suhu ini tidak biasa karena terjadi bersamaan dan kemungkinan besar disebabkan oleh peristiwa cuaca dasar yang sama.



Cara Deteksi Anomaly

- Visualisasi Data
- Metode Statistik
- Algoritma Machine Learning

Selesaikan Jika terdapat Kasus Seperti :

Anda adalah seorang analis data di sebuah perusahaan e-commerce.

Anda diberikan data penjualan harian selama sebulan terakhir.

Tugas Anda adalah untuk mengidentifikasi anomali dalam data penjualan tersebut, yang mungkin mengindikasikan adanya masalah seperti kesalahan sistem, aktivitas penipuan, atau lonjakan penjualan yang tidak biasa.