

Pertemuan 12

Klasifikasi

Konsep Klasifikasi

Pengelompokan data dimana data yang digunakan tersebut mempunyai kelas label atau target. Sehingga algoritma-algoritma untuk menyelesaikan masalah klasifikasi dikategorisasikan ke dalam supervised learning atau pembelajaran yang diawasi.

Klasifikasi Dengan KNN

Deskripsi KNN

- KNN adalah sebuah metode klasifikasi terhadap sekumpulan data berdasarkan pembelajaran data.
- Termasuk dalam supervised learning, dimana hasil query instance yang baru diklasifikasikan berdasarkan mayoritas kedekatan jarak dari kategori yang ada dalam KNN.
- Algoritma yang melakukan klasifikasi berdasarkan kedekatan lokasi (jarak) suatu data dengan data yang lain

Klasifikasi Dengan KNN


Deskripsi KNN

- Konsep dasar dari K-NN adalah mencari jarak terdekat antara data yang akan dievaluasi dengan K tetangga terdekatnya dalam data pelatihan
- Penghitungan jarak dilakukan dengan konsep Euclidean
- Jumlah kelas yang paling banyak dengan jarak terdekat tersebut akan menjadi kelas dimana data evaluasi tersebut berada.

Klasifikasi Dengan KNN

Deskripsi KNN

- Jika $k=3$ maka lingkaran hijau akan masuk dalam kategori segitiga merah
- Jika $k=5$ maka lingkaran hijau akan masuk dalam kategori segiempat biru.



Kelebihan K-NN

- Sempel
- Efektif jika data besar
- Performa cukup baik
- Tahan terhadap data latih yang noisy

Kelemahan K-NN

- Waktu komputasi tinggi jika data latih besar. Disebabkan oleh semua data diukur jaraknya untuk setiap data uji.
- Sangat sensitive dengan ciri yang redundan atau tidak relevan. Ditanggulangi dengan seleksi ciri atau pembobotan ciri.
- Tidak diketahui perhitungan jarak apa yang paling sesuai untuk dataset tertentu

Jenis-jenis perhitungan Jarak

- Jarak Euclidean

$$d(x, y) = \|x - y\| = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- Jarak Manhattan atau Cityblock

$$d(x, y) = \sum_{i=1}^n (|x_i - y_i|)$$

- Jarak Minkowski

$$d(x, y) = \|x - y\|_q = (\sum |x - y|^q)^{\frac{1}{q}}$$

- Jarak Mahalanobis

$$d(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y})^T S^{-1} (\vec{x} - \vec{y})}$$

Algoritma K-nn

1. Tentukan parameter K = jumlah tetangga terdekat.
2. Hitung jarak antara data yang akan dievaluasi dengan semua data pelatihan.
3. Urutkan jarak yang terbentuk (urut naik) dan tentukan jarak terdekat sampai urutan ke- K .
4. Pasangkan kelas (C) yang bersesuaian.
5. Cari jumlah kelas terbanyak dari tetangga terdekat tersebut, dan tetapkan kelas tersebut sebagai kelas data yang dievaluasi.

Contoh K-NN

Terdapat beberapa data yang berasal dari survei kuesioner tentang klasifikasi kualitas kertas tissue apakah baik atau jelek, dengan objek training menggunakan dua attribute yaitu daya tahan terhadap asam dan kekuatan. Dengan menggunakan $K = 4$.

X1 = Daya tahan asam (detik)	X2 = Kekuatan (Kg/m²)	Y = Klasifikasi
8	4	Baik
4	5	Jelek
4	6	Jelek
7	7	Baik
5	6	Jelek
6	5	Baik

Contoh K-NN

Terdapat beberapa data yang berasal dari survei kuesioner tentang klasifikasi kualitas kertas tissue apakah baik atau jelek, dengan objek training menggunakan dua attribute yaitu daya tahan terhadap asam dan kekuatan. Dengan menggunakan $K = 4$.

X1 = Daya tahan asam (detik)	X2 = Kekuatan (Kg/m²)	Y = Klasifikasi
8	4	Baik
4	5	Jelek
4	6	Jelek
7	7	Baik
5	6	Jelek
6	5	Baik

Akan diproduksi kembali kertas tisu dengan attribute $X1=7$ dan $X2=4$ tanpa harus mengeluarkan biaya untuk melakukan survey, maka dapat diklasifikasikan kertas tise tersebut termasuk yang baik atau jelek

Contoh K-NN

Langkah 1

Menentukan Nilai k, dimana $k=4$

Langkah 2

Menghitung jarak antara data yang akan dievaluasi dengan semua data pelatihan (training)

X1 = Daya tahan asam (detik)	X2 = Kekuatan (kg/m ²)	Square distance to query distance (7,4)
8	4	$(8-7)^2 + (4-4)^2 = 1$
4	5	$(4-7)^2 + (5-4)^2 = 10$
4	6	$(4-7)^2 + (6-4)^2 = 13$
7	7	$(7-7)^2 + (7-4)^2 = 9$
5	6	$(5-7)^2 + (6-4)^2 = 8$
6	5	$(6-7)^2 + (5-4)^2 = 2$

Contoh K-NN

Langkah 3

Urutkan jarak yang terbentuk (urut naik) dan tentukan jarak terdekat sampai urutan ke-K.

X1= Daya tahan asam (detik)	X2= Kekuatan (Kg/m ²)	Square distance to query distance (7,4)	Jarak terkecil	Apakah termasuk nearest neighbor (K)	Y= kategori nearest neighbor
8	4	$(8-7)^2 + (4-4)^2 = 1$	1	Ya	Baik
4	5	$(4-7)^2 + (5-4)^2 = 10$	5	Tidak	-
4	6	$(4-7)^2 + (6-4)^2 = 13$	6	Tidak	-
7	7	$(7-7)^2 + (7-4)^2 = 9$	4	Ya	Baik
5	6	$(5-7)^2 + (6-4)^2 = 8$	3	Ya	Jelek
6	5	$(6-7)^2 + (5-4)^2 = 2$	2	Ya	Baik

→ Data set diurutkan berdasarkan jarak dengan urutan **Ascending**

Contoh K-NN

Langkah 4

Pasangkan kelas (C) yang bersesuaian

Ada 4 data yang paling dekat yaitu (8,4) , (6,5) , (5,6), dan (7,7).

Langkah 5

Cari jumlah kelas terbanyak dari tetangga terdekat tersebut, dan tetapkan kelas tersebut sebagai kelas data yang dievaluasi.

Sehingga diperoleh baik = 3 dan jelek = 1. Dengan voting maka diperoleh bahwa tissue dengan daya tahan 7 dan Kekuatan 4 termasuk Kategori Baik.

Studi Kasus K-NN

Anda adalah seorang analis data di sebuah rumah sakit.

Anda diberikan data pasien yang berisi informasi seperti usia, tekanan darah, kadar kolesterol, dan apakah mereka memiliki penyakit jantung atau tidak.

Tugas Anda adalah membangun model klasifikasi untuk memprediksi apakah seorang pasien baru memiliki risiko penyakit jantung berdasarkan informasi tersebut.

Penyelesaian Kasus

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# Generate data pasien (contoh)
np.random.seed(42)
data = {
    'usia': np.random.randint(30, 70, 100),
    'tekanan_darah': np.random.randint(100, 160, 100),
    'kolesterol': np.random.randint(150, 250, 100),
    'penyakit_jantung': np.random.choice([0, 1], 100)
}
df = pd.DataFrame(data)

# Bagi data menjadi fitur (X) dan target (y)
X = df.drop('penyakit_jantung', axis=1)
y = df['penyakit_jantung']

# Bagi data menjadi data latih dan data uji
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Skala fitur menggunakan StandardScaler
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

Penyelesaian Studikasus

```
# Bangun model k-Nearest Neighbor
k = 5 # Jumlah tetangga terdekat
model = KNeighborsClassifier(n_neighbors=k)
model.fit(X_train, y_train)

# Prediksi pada data uji
y_pred = model.predict(X_test)

# Evaluasi model
accuracy = accuracy_score(y_test, y_pred)
print("Akurasi:", accuracy)

print("\nLaporan Klasifikasi:")
print(classification_report(y_test, y_pred))

print("\nMatriks Konfusi:")
print(confusion_matrix(y_test, y_pred))

# Contoh penggunaan model untuk prediksi baru
new_patient_data = [[50, 130, 200]] # Usia, tekanan darah, kolesterol
new_patient_data_scaled = scaler.transform(new_patient_data)
prediction = model.predict(new_patient_data_scaled)

if prediction[0] == 1:
    print("\nPasien baru memiliki risiko penyakit jantung.")
else:
    print("\nPasien baru tidak memiliki risiko penyakit jantung.")
```

Hasil Analisis

Akurasi: 0.5

Laporan Klasifikasi:

	precision	recall	f1-score	support
0	0.43	0.33	0.38	9
1	0.54	0.64	0.58	11
accuracy			0.50	20
macro avg	0.48	0.48	0.48	20
weighted avg	0.49	0.50	0.49	20

Matriks Konfusi:

```
[[3 6]
 [4 7]]
```

Pasien baru memiliki risiko penyakit jantung.

```
/usr/local/lib/python3.10/dist-packages/sklearn/base.py:465: UserWarning: X does not have valid feature names, but StandardScaler was fitted with feature names
  warnings.warn(
```