

Pertemuan 14

Algoritma Clustering

CLUSTERING

Clustering adalah metode unsupervised learning yang banyak digunakan di berbagai bidang. Dalam bidang data science, kita menggunakan analisis clustering untuk mendapatkan beberapa insight berharga

Manfaat Clustering

- *Clustering* merupakan metode segmentasi data yang sangat berguna dalam prediksi dan analisa masalah bisnis tertentu. Misalnya Segmentasi pasar, marketing dan pemetaan zonasi wilayah.
- Identifikasi obyek dalam bidang berbagai bidang seperti computer vision dan image processing.

Konsep Dasar Clustering

Hasil *clustering* yang baik akan menghasilkan tingkat kesamaan yang tinggi dalam satu kelas dan tingkat kesamaan yang rendah antar kelas. Dalam *clustering* dikenal empat tipe data. Keempat tipe data pada tersebut ialah:

1. Variabel berskala interval
2. Variabel biner
3. Variabel nominal, ordinal, dan rasio
4. Variabel dengan tipe lainnya.

Syarat Clustering

Menurut Han dan Kamber, 2012, yang harus dipenuhi oleh suatu algoritma *clustering* adalah:


1. Skalabilitas
2. Kemampuan analisa beragam bentuk data
3. Menemukan *cluster* dengan bentuk yang tidak terduga
4. Kemampuan untuk dapat menangani noise
5. Sensitivitas terhadap perubahan input
6. Mampu melakukan *clustering* untuk data dimensi tinggi
7. Interpretasi dan kegunaan

Metode Clustering

Metode *clustering* secara umum dapat dibagi menjadi dua yaitu *hierarchical clustering* dan *partitional clustering* (Tan, 2011). Sebagai tambahan, terdapat pula metode Density-Based dan Grid-Based yang juga sering diterapkan dalam implementasi *clustering*. Berikut penjelasannya:

Hierarchical clustering

Pada *hierarchical clustering* data dikelompokkan melalui suatu bagan yang berupa hirarki, dimana terdapat penggabungan dua grup yang terdekat disetiap iterasinya ataupun pembagian dari seluruh set data kedalam *cluster*



Metode Clustering

Langkah melakukan *Hierarchical clustering*:


1. Identifikasi *item* dengan jarak terdekat
2. Gabungkan *item* itu kedalam satu *cluster*
3. Hitung jarak antar *cluster*
4. Ulangi dari awal sampai semua terhubung

Contoh metode hierarchy clustering: *Single Linkage, Complete Linkage, Average Linkage, Average Group Linkage.*


Metode Clustering

Partitional Clustering


Partitional clustering yaitu data dikelompokkan ke dalam sejumlah *cluster* tanpa adanya struktur hirarki antara satu dengan yang lainnya. Pada metode *partitional clustering* setiap *cluster* memiliki titik pusat *cluster* (centroid) dan secara umum metode ini memiliki fungsi tujuan yaitu meminimumkan jarak (*dissimilarity*) dari seluruh data ke pusat *cluster* masing-masing. Contoh metode *partitional clustering*: K-Means, Fuzzy K-means dan *Mixture Modelling*.



(a) *cluster* Awal



(b) Proses Iterasi



© *cluster* Akhir

Sumber: Han dkk, 2012

Implementasi K-Means

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.cluster import KMeans

# Generate data (contoh: data pelanggan dengan pendapatan dan pengeluaran)
np.random.seed(42)
data = {
    'pendapatan': np.random.normal(50000, 15000, 100),
    'pengeluaran': np.random.normal(30000, 10000, 100)
}
df = pd.DataFrame(data)

# Tentukan jumlah cluster (misalnya, 3 cluster)
n_clusters = 3

# Inisialisasi model K-means
kmeans = KMeans(n_clusters=n_clusters, random_state=42)

# Latih model pada data
kmeans.fit(df)

# Dapatkan label cluster untuk setiap data point
labels = kmeans.labels_


# Tambahkan label cluster ke DataFrame
df['cluster'] = labels
```

Implementasi K-Means

```
# Visualisasi hasil clustering
plt.figure(figsize=(10, 6))
sns.scatterplot(x='pendapatan', y='pengeluaran', hue='cluster', data=df, palette='viridis', s=100)
plt.title('Hasil Clustering K-means')
plt.xlabel('Pendapatan')
plt.ylabel('Pengeluaran')
plt.show()

# Analisis karakteristik setiap cluster (contoh: rata-rata pendapatan dan pengeluaran)
for i in range(n_clusters):
    cluster_data = df[df['cluster'] == i]
    print(f"Cluster {i+1}:")
    print(f"  Rata-rata pendapatan: {cluster_data['pendapatan'].mean():.2f}")
    print(f"  Rata-rata pengeluaran: {cluster_data['pengeluaran'].mean():.2f}")
    print()
```

Hasil Implementasi K-Means



```
Cluster 1:  
Rata-rata pendapatan: 63940.27  
Rata-rata pengeluaran: 33468.96  
  
Cluster 2:  
Rata-rata pendapatan: 46780.02  
Rata-rata pengeluaran: 25680.13  
  
Cluster 3:  
Rata-rata pendapatan: 29321.20  
Rata-rata pengeluaran: 38802.60
```